



논문 파생변수 전략

마감일	@2026년 3월 25일
완료	☐

파생변수 전략 계획

데이터 현황

총 541,909건의 거래 데이터를 확인함. 정제 후 유효 데이터는 397,884건이며, 분석 가능한 고객은 4,338명임. 거래 기간은 2010년 12월부터 2011년 12월까지 약 1년임. 고객당 평균 거래 횟수가 4.3회(중앙값 2회)로 짧은 시계열을 가진 고객이 다수 존재함. 이를 감안하여 최소 거래 횟수 기준(3회 이상)을 설정하거나, 변수 계산 가능 여부를 명시적으로 표기하는 방식을 채택할 것을 권장함.

파생변수 전체 후보군

카테고리 1: 기본 마케팅 변수 (RFM 계열)

선행연구(Chen et al., 2012)와 겹치나, 모델의 베이스라인 역할을 하므로 반드시 포함함.

변수명	계산 방법	활용 목적
Recency	마지막 구매일 ~ 기준일(2011-12-10) 일 수	Main 종속변수(이탈) 라벨링 기준
Frequency	고객별 고유 InvoiceNo 수	구매 충성도 측정
Monetary	고객별 총 Revenue 합계	고객 가치 측정
AOV	Monetary / Frequency	평균 객단가 수준 파악
Avg Items per Order	평균 장바구니 아이템 수	탐색 vs 습관 구분
Active Months	구매가 발생한 월 수	구매 지속성 측정
Purchase Span	첫 구매 ~ 마지막 구매 일수	고객 생애 길이 파악

카테고리 2: 시간 패턴 변수 (타성 관련)

논문 초안의 '타성' 넋지 유형과 직결되는 변수군임.

변수명	계산 방법	넋지 연결
Hour Entropy	결제 시간대 분포의 Shannon 엔트로피	낮을수록 특정 시간에 고착된 타성 상태로 분류함
DayOfWeek Entropy	요일 분포의 Shannon 엔트로피	낮을수록 특정 요일에 고착된 타성 상태로 분류함
Preferred Hour	가장 많이 구매한 시간대	구매 앵커링 시점 파악
Weekend Ratio	전체 구매 중 주말 비율	라이프스타일 패턴 파악
Inter-Purchase Interval Mean	연속 구매 간격 평균(일)	구매 주기 측정
Inter-Purchase Interval Std	구매 간격 표준편차	규칙성 vs 불규칙성 측정
CV of Purchase Interval	간격 Std / 간격 Mean	구매 리듬 안정성 측정
Month Entropy	구매 월 분포의 Shannon 엔트로피	계절성 패턴 파악

카테고리 3: 장바구니 구성 변수 (인지적 효율성 관련)

변수명	계산 방법	넋지 연결
Basket Diversity Index	주문당 Unique Items / Total Quantity 평균	인지적 효율성 측정
Avg Basket Size	주문당 총 Quantity 평균	구매 규모 파악
Avg Unique Items per Basket	주문당 고유 품목 수 평균	탐색 vs 집중 구매 구분
Large Basket Ratio	Quantity > 10인 주문 비율	도매·대량 구매 성향 파악
Single Item Order Ratio	단품 주문 비율	목적 구매 성향 파악
Max Single Order Revenue	단일 주문 최대 매출	충동·특별 구매 탐지

카테고리 4: 제품 충성도 변수 (유도성·타성 관련)

변수명	계산 방법	넋지 연결
Repurchase Rate	2회 이상 구매한 StockCode 수 / 전체 구매 품목 수	유도성·타성 측정
Top Product	가장 많이 구매한 제품의 구매 비율	브랜드 고착 정도 파악

변수명	계산 방법	넛지 연결
Concentration		악
Unique Products Ratio	고유 StockCode 수 / 총 구매 건수	탐색 성향 측정
Avg Repurchase Interval	동일 제품 재구매 간격 평균(일)	유도성 반응 속도 측정
New Category Ratio	시계열상 신규 카테고리 첫 구매 비율	흥미성·탐색 성향 측정

카테고리 5: 가격 민감도 변수 (긍정성 관련)

변수명	계산 방법	넛지 연결
Avg Unit Price	구매한 제품 단가 평균	가격대 선호 파악
Price Variance	구매 단가 표준편차	가격 일관성 측정
High Price Item Ratio	단가 상위 25% 제품 구매 비율	탐색적 vs 습관적 구매 구분
Low Price Item Ratio	단가 하위 25% 제품 구매 비율	저관여 습관 구매 측정
Revenue per Visit	방문당 Revenue 평균	지출 강도 측정
Revenue Trend	후반부 6개월 vs 전반부 6개월 Revenue 비율	구매 성장·이탈 방향 탐지

카테고리 6: 반품·취소 행동 변수 (긍정성 관련)

변수명	계산 방법	넛지 연결
Return Rate	반품 건수(Quantity < 0) / 전체 주문 수	긍정성·신뢰도 측정
Has Return	반품 경험 여부 (0/1)	이진 지표
Days to Return Purchase	반품 후 다음 정상 구매까지 일수	긍정성 회복 속도 측정
Cancellation Rate	C로 시작하는 InvoiceNo 비율	구매 결정 불안정성 측정
Return Recovery Ratio	반품 후 재진입 여부 (0/1)	긍정성 넛지 효과 측정

카테고리 7: 사회적 비교 변수 (비교성 관련)

변수명	계산 방법	넛지 연결
Country Trend Alignment	거주 국가 인기 품목과 개인 장바구니 일치율	비교성 측정
Country Purchase Rank	동일 국가 내 고객 Revenue 백분위	사회적 위치 파악
UK Flag	UK 여부 (0/1)	시장 세분화 기준 변수

카테고리 8: 일관성 변수 (일관성 넋지 관련)

변수명	계산 방법	넋지 연결
Category Concentration Std	시계열상 카테고리 점유율 변화의 표준편차	낮을수록 일관된 취향으로 분류함
Revenue Consistency	주문별 Revenue의 변동계수(CV)	지출 일관성 측정
Purchase Rhythm Score	구매 간격 CV의 역수(1/CV)	구매 리듬 안정성 측정

종속변수 라벨링 계획

종속변수	라벨링 기준
이탈 여부 (Main)	Recency > 90일 → 이탈(1). 기준일은 2011-12-10으로 설정함
충동 구매 지수	평균 AOV 대비 해당 주문 1.5배 초과 & 신규 카테고리 동시 충족 시 충동(1)으로 라벨링함
구매 맥락	Hour Entropy 및 DayOfWeek Entropy 모두 하위 33% 해당 시 루틴(0), 그 외는 탐색(1)으로 분류함
예산 준수도	과거 평균 AOV 대비 해당 주문 총액 초과 여부를 기준으로 라벨링

Phase 1 — 데이터 전처리 및 변수 생성

CustomerID 결측 제거 후 고객 단위로 집계하고, 위 변수들을 순서대로 계산함. 거래 횟수가 2회 미만인 고객은 시계열 변수 계산이 불가하므로 별도 처리 방안을 마련함.

Phase 2 — 탐색적 데이터 분석

Phase 3 — 모델 실험

변수 풀을 마케팅 변수군, HCI 변수군, 전체 변수군 세 가지 조합으로 구성함. 각 조합에 대해 Random Forest, XGBoost, Logistic Regression을 적용하여 성능을 비교함. 이를 통해 HCI 변수가 예측력에 실질적으로 기여하는지 검증함.

Phase 4 — SHAP 분석 및 넋지 매핑

최종 모델에서 SHAP 가중치를 산출하고, 상위 기여 변수를 7가지 넋지 유형에 매핑하여 UI 설계 전략과 연결함.