

데이터셋에 대한 선행 연구

🌀 진행 상태 읽기 전

▼ Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining (온라인 소매 산업을 위한 데이터 마이닝: 데이터 마이닝을 활용한 RFM 모델 기반 고객 세분화 사례 연구)

연구 목적

소규모 온라인 소매업체가 데이터 마이닝 기술을 활용해 고객을 더 잘 이해하고, 고객 중심 마케팅을 효과적으로 수행할 수 있도록 지원하는 것을 목표로 합니다.

연구 대상 및 데이터

- 영국 기반의 소규모 온라인 기념품 판매 업체
- 2011년 1월~12월 거래 데이터 사용
- 총 22,190건의 유효 거래, 4,381개의 고유 우편번호(고객)

연구 방법

RFM 모델 을 기반으로 세 가지 핵심 변수를 사용합니다.

변수	의미
Recency	최근 구매 시점
Frequency	구매 빈도
Monetary	총 구매 금액

분석 절차는 다음과 같습니다.

- 데이터 전처리 — 변수 선택, 결측치 제거, 정규화
- K-means 클러스터링 — 3, 4, 5개 클러스터 비교 후 5개 클러스터 최종 선택
- 의사결정나무(Decision Tree) — 가장 다양한 집단(Cluster 3) 세분화

클러스터링 결과 (5개 그룹)

클러스터	고객 수	비율	특징
1	527명	14%	하반기 구매 없음, 최저 수익 그룹

클러스터	고객 수	비율	특징
2	636명	17%	낮은 구매 빈도, 중간 수준 지출
3	1,748명	47%	일반 소비자, 수익성 불확실 (가장 큰 그룹)
4	627명	17%	높은 빈도·금액, 두 번째 고수익 그룹
5	188명	5%	연간 꾸준한 구매, 전체 매출의 25.5% 기여 (최고 수익 그룹)

핵심 인사이트: 상위 22%의 고객이 전체 매출의 약 **60%** 를 창출합니다.

주요 결론 및 시사점

- 데이터 마이닝에서 가장 시간이 많이 소요되는 단계는 **데이터 전처리**와 **모델 해석·평가**
- 고객 그룹별 맞춤형 마케팅 전략 수립 가능
- 향후 연구 과제로 **연관 분석**, **고객 생애 가치 예측**, **지리적 분석** 등을 제안

▼ Finding Robust Itemsets under Subsampling(부분표본추출 환경에서 견고한 항목집합 찾기)

연구 목적

빈발 패턴 마이닝(Frequent Pattern Mining)에서 발생하는 **패턴 폭발(Pattern Explosion)** 문제를 해결하기 위해, 서브샘플링(Subsampling) 기반의 새로운 패턴 축소 프레임워크를 제안합니다.

핵심 아이디어: Robustness(강건성)

어떤 아이템셋의 속성(예: closedness)이 **원본 데이터의 랜덤 서브셋에서도 얼마나 자주 성립하는가**를 확률로 측정합니다.

Robustness = 랜덤 서브샘플 D_α 에서 해당 속성이 성립할 확률

- α : 각 트랜잭션을 서브샘플에 포함시킬 확률 (0~1)
- Robustness가 높을수록 → 데이터 변화에 강건한 패턴

분석 대상 4가지 아이템셋 유형

유형	설명	Robustness 계산 복잡도
Closed	같은 support를 가진 아이템셋 중 최대	$O(2^{(K- X)})$ — 비실용적

유형	설명	Robustness 계산 복잡도
Free	같은 support를 가진 아이템셋 중 최소	$O(X)$ — 효율적
Non-derivable	support를 부분집합으로부터 유도 불가	$O(2^{ X })$ — 효율적
Totally Shattered	모든 가능한 값 조합이 데이터에 존재	$O(2^{ X })$ — 효율적

Closed 아이템셋을 제외한 나머지 세 가지는 **해석적으로(analytically) 계산 가능**하며, 실제 샘플링 없이도 Robustness를 구할 수 있습니다.

파라미터-프리 랭킹

α 값에 의존하지 않는 **아이템셋 순위 결정 방법**도 제안합니다.

- α 가 1에 가까운 근방에서 아이템셋 간 순위는 α 와 무관하게 일정함을 증명
- **Margin Vector**를 정의해, 다항식 전개 없이 순위 비교 가능
 - Free / Totally Shattered: 정확한 순위 계산 가능
 - Closed / Non-derivable: 휴리스틱 추정 사용

실험 결과

패턴 수 감소 효과

- Zoo 데이터셋(동물 101마리, 42개 속성)에서 α 와 최소 Robustness 임계값 조정 시 free 아이템셋 수를 **최대 2 오더(100배) 감소**
- 다양한 데이터셋에서 Robustness 임계값 0.9 적용 시 **유의미한 패턴 수 축소** 확인

랭킹 품질 (Kendall's τ)

- 파라미터-프리 랭킹과 실제 Robustness 기반 랭킹 간의 거리값이 전반적으로 매우 작음 → **두 랭킹이 유사함**을 의미
- α 가 낮아질수록 거리가 증가하는 경향 (예상된 결과)

Top-k Closed 아이템셋 예시 (re0 뉴스 데이터)

- Support 기반 순위와 달리, **빈도는 낮지만 강건한 아이템셋**이 더 높은 순위를 차지
- 예: 'bank pct rate'가 더 빈번한 'bank pct'보다 높은 순위

결론 및 의의

- 실제 샘플링 없이 Robustness를 **해석적으로 계산**할 수 있어 실용적

- 통계적 귀무가설이나 노이즈 모델 가정이 **불필요**
- 보고되는 패턴은 해당 속성을 **실제로 만족하는** 패턴의 부분집합 (근사 패턴 아님)
- 향후 연구로 클러스터링, 분류, 연관 규칙 생성 등에의 응용을 제안

▼ Moment-Based Quantile Sketches for Efficient High Cardinality Aggregation Queries (효율적인 고용량 집계 쿼리를 위한 모멘트 기반 분위수 스케치)

연구 목적

Druid, Spark 같은 OLAP 엔진에서 고차원 데이터의 분위수(Quantile) 집계 쿼리를 처리할 때, 수십만 건의 서머리 병합(Merge) 이 병목이 되는 문제를 해결하고자 합니다.

핵심 아이디어: Moments Sketch

통계학의 **모멘트법(Method of Moments)** 과 **최대 엔트로피 원리(Maximum Entropy Principle)** 를 결합하여, 극히 작은 용량으로 분위수를 효율적으로 추정합니다.

저장하는 통계량은 아래와 같습니다.

통계량	설명
xmin, xmax	최솟값, 최댓값
n	데이터 수
$\mu_i = (1/n)\sum x^i$	표본 모멘트 (k차)
$v_i = (1/n)\sum \log^i(x)$	로그 모멘트 (k차)

- **메모리:** 단 **200 bytes** (k=10 기준)
- **병합 시간:** **50 nanoseconds** 이하
- 병합 연산이 단순한 덧셈이라 매우 빠름

분위수 추정 방법

저장된 모멘트만으로는 분포가 유일하게 결정되지 않기 때문에, **최대 엔트로피 분포**를 이용해 가장 편향이 없는 분위수 추정치를 계산합니다. 수치 최적화(Newton's method)로 해를 구하며, Chebyshev 다항식 기반으로 수치 안정성과 계산 효율을 개선합니다.

Cascade (임계값 쿼리 최적화)

수천 개 서브그룹에 대해 "99번째 백분위수가 특정 임계값 이상인가?"를 판별할 때, 매번 최대 엔트로피 추정을 하면 비용이 큼니다. 이를 위해 **3단계 Cascade** 를 도입합니다.

1. **단순 범위 체크** (xmin, xmax 비교) — 가장 빠름

2. Markov 부등식 기반 경계 — 중간
3. RTT 경계 — 더 정밀
4. 최대 엔트로피 추정 — 최종 판별 (필요 시에만)

각 단계에서 판별 가능하면 다음 단계로 넘어가지 않아 전체 처리량이 크게 향상됩니다.

성능 결과 요약

병합 및 쿼리 속도

비교 항목	결과
병합 속도 (vs 유사 정확도 서머리)	최대 50배 빠름
전체 쿼리 시간 (단독)	15~50배 빠름
Druid 엔진 통합 시	최대 60배 빠름
MacroBase 엔진 통합 시	최대 7배 빠름
Cascade 적용 시 (임계값 쿼리)	최대 25배 처리량 향상
슬라이딩 윈도우 쿼리	Merge12 대비 13배 빠름

병합 수가 **10,000건 이상**일 때 Moments Sketch의 우위가 두드러짐

정확도

- 대부분의 실제 데이터셋에서 $\epsilon \leq 1\%$ (**0.01**) 오차 달성
- 단, **이산형(low-cardinality) 데이터셋**에서는 최대 엔트로피 원리의 정확도가 떨어지며, 고유값이 5개 미만이면 수렴 실패

추정 시간

- 분위수 추정에 평균 **약 2ms** 소요 (병합 시간보다 느리나 1ms 이하 최적화 가능)
- 최대 엔트로피 사용 시, 사용하지 않는 추정기보다 **5배 이상 낮은 오차**, 일반 솔버보다 **최대 200배 빠른 추정**

한계 및 적용 조건

- 이산적이거나 고유값이 적은 데이터에서는 성능 저하
- $k \geq 16$ 이상에서 부동소수점 정밀도 문제 발생
- 병합 수가 100건 이하일 때는 추정 비용이 지배적 → 다른 서머리가 유리

결론

Moments Sketch는 **200 bytes의 초소형 메모리**와 **50ns의 병합 속도**로, 수십만 건의 집계가 필요한 고차원 대화형 분석 환경에서 기존 대비 압도적인 속도 향상을 제공하는 실용적인 분위수 스케치입니다.

▼ **Efficient and Scalable Multi-task Regression on Massive Number of Tasks (대규모 작업에 대한 효율적이고 확장 가능한 멀티태스킹 회귀 분석)**

연구 목적

유통·교통 등 실세계에서 **수만 개 이상의 태스크**를 가진 대규모 다중태스크 학습(MTL) 문제를 기존 방법보다 **정확하고 훨씬 빠르게** 해결하는 알고리즘을 제안합니다.

핵심 아이디어: CCMTL

Convex Clustering Multi-Task regression Learning (CCMTL) 은 볼록 클러스터링 (Convex Clustering)을 다중태스크 학습 프레임워크에 통합한 방법입니다.

목적 함수는 다음과 같습니다.

예측 오차 최소화 + k-NN 그래프 상 유사 태스크 간 모델 차이 최소화 (ℓ_2 정규화)

- k-최근접 이웃(k-NN) 그래프로 태스크 간 관계를 구성
- ℓ_1 이 아닌 ℓ_2 노름을 사용해 클러스터링 효과와 안정성을 동시에 확보

최적화 방법

직접 행렬 역행렬 계산 시 계산량이 $O((PT)^3)$ 으로 폭발하는 문제를 해결하기 위해 **보조 변수 L**을 도입한 **교대 최적화**를 사용합니다.

1. **L 업데이트**: 해석적 공식으로 즉시 계산
2. **W 업데이트**: 구조화된 선형 시스템 풀기 → **CMG(Combinatorial MultiGrid)** 알고리즘 적용

CMG는 라플라시안 행렬 구조를 활용해 **태스크 수에 선형(linear)으로 스케일**합니다.

수렴 보장: 전역 최적해(Global Optimum)로의 수렴이 이론적으로 증명됨

실험 결과

정확도 (RMSE 기준, 낮을수록 좋음)

데이터셋	CCMTL	차순위 경쟁 방법
Syn (합성)	1.192	BiFactor: 1.219
School	10.020	CMTL: 10.116
Sales (유통)	2.793	STL: 2.861
Ta-Feng (유통)	0.767	FuseMTL: 0.764
Alighting (교통)	2.795	SRMTL: 2.793
Boarding (교통)	2.928	SRMTL: 2.926

대부분의 데이터셋에서 **CCMTL**이 8개 SoA 방법 중 최고 또는 통계적으로 동등한 성능 달성

속도 비교 (Ta-Feng: 23,812 태스크)

방법	학습 시간
CCMTL	약 35초
FuseMTL	약 8,483초 (2.4시간)
RMTL	약 181초
CMTL / SRMTL / BiFactor / TriFactor	24시간 초과 (미완료)

확장성 (ScaleSyn: 5k ~ 160k 태스크)

방법	스케일링 특성
CCMTL	선형(Linear)
RMTL	선형 (단, CCMTL보다 느림)
L21, Trace, FuseMTL, SRMTL	초선형(Super-linear)
CMTL, BiFactor, TriFactor	40k 태스크에서 24시간 초과

160k 태스크 기준: CCMTL은 약 **500초**, RMTL은 약 **800초** 소요

결론

CCMTL은 수만~수십만 개의 태스크를 가진 실세계 대규모 회귀 문제에서 **정확도와 계산 효율성을 동시에** 달성하는 유일한 방법으로, 태스크 수에 선형으로 확장되며 전역 최적 수렴이 보장된 실용적인 알고리즘입니다.

▼ **Efficient Mining Top-k Regular-Frequent Itemset Using Compressed Tidsets (압축된 Tidset을 사용한 효율적인 상위 k개 정기 빈번 항목 집합 마이닝)**

연구 목적

트랜잭션 데이터베이스에서 **지지도 임계값 없이** 시간적 규칙성(Temporal Regularity)과 빈도를 동시에 만족하는 **상위 k개 아이템셋**을 효율적으로 발굴하는 알고리즘을 제안합니다.

핵심 개념

Regular-Frequent Itemset이란 두 조건을 동시에 만족하는 패턴입니다.

조건	의미
Frequent	지지도(등장 횟수)가 높음
Regular	데이터베이스 전반에 걸쳐 일정한 간격으로 등장 (최대 공백 $\leq \sigma_r$)

Top-k 방식을 채택해 사용자가 임계값 대신 **원하는 결과 수 k**만 지정하면 됩니다.

핵심 아이디어: Compressed Tidset

기존 MTKPP 알고리즘의 병목인 **트랜잭션 ID 집합(tidset) 교차 연산**을 개선하기 위해 **압축 tidset**을 제안합니다.

연속된 트랜잭션 ID 그룹을 시작(양수)과 끝(음수) 두 값만으로 압축합니다.

예시: $T^a = \{1, 2, 3, 4, 6, 7, 8, 9, 10, 11, 12\} \rightarrow CT^a = \{1, -3, 6, -6\}$

- 11개 ID $\rightarrow$ 4개 값으로 압축 (64% 절감)
- 밀집(Dense) 데이터셋일수록 압축 효과가 극대화됨

알고리즘: TR-CT

2단계 구조로 동작합니다.

1단계 - Top-k 리스트 초기화

- 데이터베이스를 **단 1회 스캔**
- 각 아이템의 지지도·규칙성·압축 tidset을 수집
- σ_r 초과 항목 제거 후 지지도 내림차순 정렬
- k개 초과 항목 제거

2단계 - Top-k 마이닝

- **Best-first 탐색**으로 높은 지지도 아이템셋부터 처리
- 동일 접두사를 가진 후보쌍 병합 $\rightarrow$ 압축 tidset 교차 연산
- 새 아이템셋이 k번째 지지도보다 높고 규칙성 조건 만족 시 리스트 갱신

실험 결과

사용 데이터셋 (UCI ML Repository)

데이터셋	아이템 수	평균 길이	트랜잭션 수	유형
accidents	468	338	340,183	밀집
connect	129	43	67,557	밀집
pumsb	2,113	74	49,046	밀집
retail	16,469	10.3	88,162	희소

실행 시간

- 밀집 데이터셋 (accidents, connect, pumsb): TR-CT가 MTKPP 대비 **명확히 빠름** (k 와 σ_r 의 다양한 설정 모두에서)
- 희소 데이터셋 (retail): 두 알고리즘이 유사한 성능 → 연속 ID가 적어 압축 효과 미미

메모리 사용량

- 밀집 데이터셋: TR-CT가 MTKPP보다 **훨씬 적은 메모리** 사용
- 희소 데이터셋: 두 알고리즘이 유사

유지 TID 수

- 밀집 데이터셋에서 TR-CT는 MTKPP보다 **훨씬 적은 수의 TID**를 유지하며, 이것이 속도-메모리 이점의 근본 원인

결론 및 의의

TR-CT는 압축 **tidset**이라는 간결한 표현을 활용해 Top-k 규칙-빈발 아이템셋 마이닝에서 기존 MTKPP 대비 실행 시간과 메모리 모두에서 우수한 성능을 달성합니다. 특히 **밀집 데이터셋에서 효과가 두드러지며**, 희소 데이터셋에서는 동등한 수준을 보입니다.

▼ **Layered critical values: a powerful direct-adjustment approach to discovering significant patterns (계층화된 임계값: 중요한 패턴을 발견하기 위한 강력한 직접 조정 접근법)**

연구 목적

패턴 마이닝(연관 규칙 등)에서 **거짓 패턴(False Discovery)** 을 통제하는 기존 직접 조정 (Direct-Adjustment) 방식의 한계, 즉 탐색 공간이 커질수록 **진짜 패턴도 놓치는 문제**를 개선하는 새로운 기법을 제안합니다.

배경: 거짓 발견 문제

패턴 마이닝은 샘플 데이터에서 패턴을 찾기 때문에, 실제로는 무의미한 **가짜 패턴을 발견할 위험**이 존재합니다. 이를 통제하는 대표적인 두 가지 방법은 다음과 같습니다.

방법	설명	장단점
직접 조정법 (Direct-Adjustment)	Bonferroni 보정으로 탐색 공간 전체를 기준으로 임계값 조정	Top-k 마이닝 지원, 전체 데이터 활용. 단, 탐색 공간이 커질수록 임계값이 극도로 낮아져 진짜 패턴도 놓침
홀드아웃 평가법 (Holdout)	데이터를 탐색/평가 세트로 분리	적용이 쉽고 강력하나 Top-k 마이닝과 통합 어려움, 데이터 절반만 활용

핵심 아이디어: Layered Critical Values (LCV)

탐색 공간의 **레벨(Antecedent 크기)**마다 서로 다른 임계값을 부여합니다.

기존 균일 임계값: $\alpha' = \alpha / (\text{전체 탐색 공간 크기})$

LCV 방식: $\alpha'_L = \alpha / (L_{\max} \times S_L)$

- L: 현재 레벨 (전건 아이템 수)
- $L_{\max}$: 최대 레벨
- S_L : 해당 레벨의 탐색 공간 크기

핵심 효과: 탐색 공간을 더 큰 레벨로 확장해도, 기존 레벨의 임계값이 최대 $L_{\max}$ 배만큼만 감소하여 이미 발견 가능한 패턴들이 거의 탈락하지 않습니다. 기존 균일 방식에서는 동일 상황에서 임계값이 최대 **10^1 배**까지 감소할 수 있었습니다.

실험 결과

실험 1 (합성 데이터 — 진짜 패턴 수 고정)

- 탐색 공간을 늘려도 LCV는 기존 방식보다 **더 많은 진짜 패턴 유지**
- 거짓 발견율은 여전히 $\alpha=0.05$ 기준 엄격하게 통제됨

실험 2 (합성 데이터 — 레벨마다 진짜 패턴 추가)

- 대부분의 데이터 크기와 탐색 공간 크기에서 LCV가 **더 많은 패턴 발견**
- 일부 조건에서 소폭 감소하나 거짓 발견율 통제는 유지

실험 3 (실제 데이터 10개 — UCI/KDD)

- 대부분의 데이터셋·레벨 조합에서 **LCV > 균일 방식**

- Splice Junction: LCV가 **3배 이상** 더 많은 규칙 발견
- Retail, TICDATA: LCV가 **2배 이상** 더 많은 규칙 발견
- 홀드아웃 방식 대비로도 경쟁력 대폭 향상 (홀드아웃 우위: 46 → 33건, 직접조정 우위: 13 → 26건)

실험 4 (Top-k 패턴 마이닝)

- Splice Junction에서 균일 방식은 247개 규칙만 발견, LCV는 **요청한 1,000개 모두** 발견
- Retail: LCV 발견 규칙의 평균 지지도가 균일 방식의 **1.5배**
- 홀드아웃 방식은 Top-k와 통합 불가 → LCV만 적용 가능

결론

LCV는 탐색 공간의 레벨별로 차별화된 임계값을 부여함으로써, 거짓 발견에 대한 엄격한 통제를 유지하면서도 **발견되는 진짜 패턴의 수를 크게 증가**시킵니다. 특히 홀드아웃 방식이 지원하지 못하는 **Top-k 패턴 마이닝**에도 직접 적용 가능하다는 점에서 실용적 가치가 높습니다.

▼ Discovering Significant Patterns (부분표본추출 환경에서 견고한 항목집합 찾기)

핵심 문제

패턴 탐색(association rule discovery 등)은 대규모 탐색 공간에서 수많은 패턴을 평가하기 때문에 **다중 비교 문제(multiple comparisons problem)**가 발생합니다. 즉, 실제로는 무의미한 패턴이 우연히 기준을 통과하는 **Type-1 오류(허위 발견)** 위험이 매우 높습니다. n 개의 독립 패턴을 유의수준 κ 로 검정할 경우 적어도 하나의 오류가 발생할 확률은 $1 - (1 - \kappa)^n$ 으로 빠르게 1에 수렴합니다.

기존 방법의 한계

기존 접근법들(최소 지지도, 최소 신뢰도, lift, redundancy 제거 등)은 발견된 패턴이 단순히 샘플 데이터의 우연적 결과인지를 통계적으로 검증하지 않았습니다. 일부 시스템(STUCCO 등)이 Bonferroni 보정을 시도했지만, 탐색한 패턴 수가 아닌 실제 검정을 수행한 패턴 수만으로 보정해 통계적으로 불충분했습니다.

제안하는 두 가지 기법

1. Direct Adjustment (직접 보정)

- 탐색 공간의 크기 s 를 계산하고, 유의수준을 α/s 로 Bonferroni 보정하여 적용

- 모든 데이터를 패턴 탐색과 통계 검정 모두에 활용 가능
- k-optimal 패턴 탐색과 호환

2. Holdout Evaluation (홀드아웃 평가)

- 데이터를 ****탐색용(exploratory)****과 **검증용(holdout)** 으로 분리
- 탐색 데이터에서 후보 패턴을 발굴한 뒤, 홀드아웃 데이터에서 통계 검정 (Bonferroni 또는 Holm 절차 적용)
- 기존 패턴 탐색 시스템에 **래퍼(wrapper)** 형태로 쉽게 적용 가능
- 탐색 중 필터링(filtering)을 사전에 적용하면 검정 대상 패턴 수가 줄어 검증력이 향상 됨

실험 결과 요약

항목	결과
보정 없는 기법	무작위 데이터에서도 수천 개의 허위 패턴 발견
Direct Adjustment	허위 발견 완전 차단 (소규모 탐색 공간에서 유리)
Holdout Evaluation	허위 발견 완전 차단 (대규모 탐색 공간에서 더 강력)
실세계 데이터	기존 방법 발견 패턴의 99% 이상이 통계 검정 미통과 (예: TICDATA 2000)

결론

두 기법 모두 **실험 전체 Type-1 오류율을 엄격하게 통제**하면서도 실제 패턴을 발견하는 데 충분한 검증력을 가집니다. 홀드아웃 방식은 유연성과 적용 용이성이 높고, 직접 보정 방식은 k-optimal 탐색에 유리합니다. 이 연구는 전통적인 통계 기법을 대규모 패턴 탐색에 확장 적용한 것에 의의가 있습니다.

▼ Moment-Based Quantile Sketches for Efficient High Cardinality Aggregation Queries (효율적인 고용량 집계 쿼리를 위한 모멘트 기반 분위수 스케치)

핵심 문제

Druid, Spark 같은 OLAP 엔진은 고차원 데이터의 분위수(quantile) 쿼리를 처리하기 위해 **병합 가능한 요약 구조(mergeable summaries)** 를 사용합니다. 그러나 수십만 개의 요약을 병합해야 하는 고카디널리티 환경에서는 **병합 시간이 심각한 병목**이 됩니다. 예를 들어, 100만 개의 GK-sketch를 순차 병합하면 3초 이상이 소요되어 인터랙티브 쿼리가 불가능합니다.

제안: Moments Sketch

통계학의 **적률법(Method of Moments)** 과 **최대 엔트로피 원리(Maximum Entropy Principle)** 를 결합한 새로운 분위수 요약 구조입니다.

저장하는 통계량

항목	내용
기본 정보	min, max, count
표준 적률	$\mu_i = (1/n) \sum x^i$
로그 적률	$v_i = (1/n) \sum \log^i(x)$
메모리	200 bytes (k=10 기준)
병합 속도	50ns 이하

로그 적률은 long-tail 분포(예: 네트워크 지연)에서 정확도를 크게 향상시킵니다.

분위수 추정 방법

스케치에 저장된 적률 값을 만족하는 분포는 무수히 많기 때문에, **최대 엔트로피 원리**를 적용하여 "가장 덜 편향된" 분포를 선택합니다. 이를 지수족(exponential family) 분포로 표현하고, Newton's method로 최적화합니다. 수치 안정성을 위해 **Chebyshev 다항식 기저**를 사용하고, 적분 계산 효율화를 통해 추정 시간을 기존 대비 200배 단축합니다.

Cascade를 활용한 임계값 쿼리 최적화

"99번째 백분위수가 100ms를 초과하는 앱 버전 탐색"과 같은 **임계값 쿼리(threshold query)**는 수천 개 서브그룹에 대해 분위수를 반복 추정해야 합니다. 이를 위해 비용이 낮은 순서로 단계적으로 필터링하는 **캐스케이드**를 도입합니다.

단계는 다음과 같습니다. 먼저 범위 체크(xmin, xmax)로 즉시 판별 가능한 경우를 처리하고, 다음으로 Markov 부등식 기반 bound를 계산한 뒤, RTTBound(더 정밀한 bound)를 적용하고, 마지막으로 최대 엔트로피 분위수 추정을 수행합니다. 이 캐스케이드는 직접 추정 대비 **최대 25배** 빠른 처리량을 제공합니다.

실험 결과 요약

항목	성능
병합 속도	동급 정확도 대비 16~50배 빠름
분위수 오차	200 bytes로 $\epsilon \leq 1\%$ 달성
MacroBase 통합	쿼리 속도 최대 7배 향상
Druid 통합	쿼리 속도 최대 60배 향상
슬라이딩 윈도우 쿼리	Merge12 대비 13배 빠름

병합 횟수가 10,000회 이상일 때 moments sketch가 특히 유리하며, 반대로 병합이 적고 추정 비용이 지배적인 경우($n_{\text{merge}} \leq 100$)에는 다른 방법이 더 유리합니다.

한계

이산형(discrete) 저카디널리티 데이터(구별되는 값이 5개 미만)에서는 최대 엔트로피 솔버가 수렴에 실패할 수 있습니다. 또한 부동소수점 정밀도 한계로 인해 일반적으로 $k \leq 15$ 정도의 적률만 안정적으로 활용 가능합니다.

결론

Moments Sketch는 통계적 적률이라는 단순한 요약만으로 극도로 빠른 병합(50ns)과 충분한 정확도($\epsilon \leq 1\%$)를 동시에 달성합니다. 특히 수십만 개의 요약을 병합해야 하는 대규모 OLAP 환경에서 기존 방법 대비 압도적인 성능 향상을 보이며, 기존 시스템에 사용자 정의 집계 함수 형태로 손쉽게 통합 가능하다는 실용적 장점도 갖습니다

▼ **Eksplorasi dan Visualisasi Data Transaksi Online Retail Untuk Mendukung Pengambilan Keputusan Bisnis (온라인 리테일 트랜잭션 데이터 탐색 및 시각화를 통한 비즈니스 의사결정 지원)**

연구 목적

이커머스 성장으로 발생하는 방대한 트랜잭션 데이터를 **탐색적 데이터 분석(EDA)** 과 **인터랙티브 대시보드**를 통해 분석하여 비즈니스 의사결정을 지원하는 것이 목적입니다.

연구 방법

데이터셋: UCI Online Retail 데이터셋 (2010~2011년, 총 541,909건 트랜잭션)

데이터 전처리 (Python / Google Colab): Quantity·UnitPrice가 0 이하인 데이터 제거, CustomerID 결측 데이터 제거, 중복 데이터 제거, Revenue(= Quantity × UnitPrice) 파생 변수 추가를 거쳐 최종 **392,692건**의 유효 데이터를 확보했습니다.

분석 도구: Looker Studio 인터랙티브 대시보드 (기간 필터·국가 필터 포함)

주요 분석 결과

거래 및 수익 트렌드

월별 거래 건수는 뚜렷한 계절성(seasonality)을 보였으며, 거래량 증가가 반드시 수익 증가로 이어지지는 않았습니다. 이는 단가가 수익에 미치는 영향이 크기 때문입니다.

베스트셀러 제품 분석

거래량 기준 상위 7개 제품과 수익 기준 상위 7개 제품이 서로 다르게 나타났습니다. 판매량

이 많아도 단가가 낮으면 수익 기여도가 낮을 수 있어, **판매량과 수익성을 함께 고려한 제품 전략**이 필요합니다.

지역별 판매 분포

United Kingdom이 전체 수익의 약 **80%** 를 차지하며 압도적으로 시장을 지배했습니다. 그 외 Netherlands, EIRE(아일랜드), Germany, France, Australia, Spain 순으로 수익 기여도가 나타났으며, 이들 국가도 성장 잠재력을 가지고 있습니다.

결론 및 시사점

인터랙티브 대시보드를 활용한 EDA는 다음과 같은 의사결정을 지원합니다.

- **프로모션 전략:** 계절성 패턴을 활용해 적절한 판촉 시점 결정
- **재고 관리:** 수익성 높은 제품을 우선 관리하는 전략 수립
- **시장 확장:** 영국 외 잠재 시장 국가를 대상으로 한 진출 전략 수립

평가

이 논문은 기계학습 모델링 없이 순수하게 EDA와 시각화만으로 실용적인 비즈니스 인사이트를 도출했다는 점이 특징입니다. 다만 예측 모델링이나 통계적 검정이 없어 발견된 패턴의 유의성을 수치적으로 확인하기 어렵다는 한계가 있습니다.

▼ **Predicting e-commerce product prices through the integration of variational mode decomposition and deep neural networks (VMD와 심층신경망을 결합한 이커머스 상품 가격 예측)**

핵심 문제

이커머스 상품 가격은 **비선형·비정상(nonlinear & nonstationary) 시계열** 특성을 가지므로 전통적인 선형 모델로는 정확한 예측이 어렵습니다. 또한 상품 생애주기에 따라 데이터 특성이 달라지는데, 기존 방법은 이를 충분히 반영하지 못했습니다.

제안 모델: VMD-DNN

변분 모드 분해(VMD)와 **심층신경망(DNN)**을 결합한 하이브리드 예측 프레임워크입니다.

모델 구성 4단계

Step 1: 최적 K값 결정

최소 퍼지 엔트로피(Minimum Fuzzy Entropy) 기준을 사용하여 VMD 분해에서 최적 모드 수(K)를 자동으로 결정합니다. 기존의 샘플 엔트로피(이진 함수 기반) 대신 퍼지 멤버십 함수를 사용해 더 연속적이고 안정적인 복잡도 측정이 가능합니다.

Step 2: VMD 분해

결정된 K값으로 원본 가격 시계열을 K개의 IMF(고유 모드 함수) 성분으로 분해하여, 복잡한 시계열을 단순하고 부드러운 부분 수열로 변환합니다.

Step 3: DNN 예측

분해된 각 IMF 성분을 DNN에 개별 입력하여 예측값을 산출합니다. DNN 입력 특징으로는 일별 가격, 제품 크기, 계절성 판매량, 경쟁사 가격, 사용자 평점, 프로모션 할인율, 인플레이션을 7가지를 사용합니다.

Step 4: 예측 통합

각 IMF 성분의 예측값을 선형 합산하여 최종 가격 예측값을 도출합니다.

DNN 구조

7개 레이어(입력층 → Dense(128) → Dropout → Dense(64) → Dropout → Dense(3) 출력층)로 구성되며, Adam 옵티마이저와 ReLU 활성화 함수를 사용합니다. 최적 하이퍼파라미터는 배치 크기 16, 학습률 0.01, ReLU 조합입니다(정확도 89.2%, 손실 0.20).

실험 결과 (성능)

사용 데이터셋: Amazon Product Reviews, E-commerce Price Prediction Dataset, Online Retail Dataset (UCI)

비교 모델: ELM, DNN, VMD-ELM, VMD-SVR

오차 지표 비교 (낮을수록 우수)

데이터셋	지표	VMD-DNN	오차 감소율
E-commerce Price Prediction	MAPE	0.6578	66.5% ↓
Online Retail	MAPE	0.5414	70.4% ↓
Amazon Reviews	RMSE	0.2481	최저
Amazon Reviews	MAE	0.1546	최저

방향 대칭성(DS) 비교 (높을수록 우수)

데이터셋	VMD-DNN	VMD-ELM	VMD-SVR	DNN
Amazon Reviews	86.25	79.3	~70	~65
E-commerce	87.5	79.8	~70	~65
Online Retail	최고	79.3	하위	하위

VMD-DNN은 가격의 **상승/하락 방향 예측 정확도** 에서도 모든 비교 모델을 압도했습니다.

결론 및 한계

VMD로 복잡한 가격 시계열을 단순 부분 수열로 분해한 후 DNN으로 예측하는 분해-통합 전략이 단일 모델 대비 크게 우수했으며, VMD의 분해 능력을 DNN이 **4% 추가 향상**시켰습니다.

다만 데이터 품질에 민감하고, 특정 상품·기간에서 일반화 성능이 제한될 수 있으며, 단순한 예측 문제에는 과도하게 복잡한 모델일 수 있다는 한계가 있습니다. 향후 계절성·프로모션 등 동적 특성을 모델에 통합하는 연구가 제안됩니다.